



Informe Evaluación Parcial 3

a) Portada

- **Nombre de la asignatura y sección:** Minería de datos
- **Nombre del docente:** Pablo Cesar Silva Mancilla
- **Nombre del alumno:** Fabián Lecaros Ampuero
- **Fecha de entrega:** 23/06/2026

b) Introducción

Contextualización del Problema

El presente proyecto aborda el problema de abandono de clientes en una empresa de telecomunicaciones con operación en la Zona Sur. El análisis se enfocará exclusivamente en el segmento **Residencial**, utilizando información comercial, técnica, geográfica, de servicios contratados, reclamos y abandonos voluntarios posteriores al 31 de marzo de 2024. El abandono parcial representa un riesgo relevante para la compañía, ya que reduce ingresos recurrentes, debilita la relación comercial y puede anticipar una pérdida total del cliente.

Objetivos de la Minería de Datos

El objetivo del proyecto es aplicar técnicas de minería de datos para identificar patrones asociados al abandono, segmentar clientes residenciales según su comportamiento y apoyar decisiones de retención. Para ello se utilizarán modelos supervisados orientados a predecir abandono, modelos no supervisados para descubrir grupos de clientes con características similares y reglas de asociación para detectar combinaciones de servicios relevantes. Estos resultados permitirán transformar los datos disponibles en insights accionables para priorizar campañas de fidelización y reducir la pérdida de clientes.

Fase 1: Comprensión del Negocio (Business Understanding)

El caso de estudio se centra en una empresa de telecomunicaciones con operación en la Zona Sur, que requiere anticipar el abandono de clientes para ejecutar acciones de retención antes de que la pérdida se materialice. Para este proyecto se trabajará exclusivamente con el segmento **Residencial**, debido a su relevancia en la base de clientes, su relación directa con ingresos recurrentes y su potencial para estrategias de fidelización mediante paquetes de servicios.

El problema central corresponde al **abandono parcial de clientes residenciales**, entendido como la baja voluntaria de uno o más servicios contratados durante los meses posteriores al corte de información del 31 de marzo de 2024. Este fenómeno afecta directamente los ingresos de la compañía, reduce el valor del cliente en el tiempo y puede actuar como una señal temprana de abandono total.

Desde la perspectiva del negocio, el objetivo principal es identificar anticipadamente a los clientes con mayor probabilidad de abandono, utilizando variables asociadas a servicios contratados, antigüedad, facturación, reclamos, fallas técnicas, características geográficas y servicios adicionales. Con ello, la empresa podrá priorizar campañas de retención, diseñar ofertas personalizadas y focalizar recursos comerciales en clientes con mayor riesgo.

Los objetivos organizacionales del proyecto son:

- Reducir la pérdida de clientes residenciales mediante acciones preventivas de retención.
- Identificar factores que aumentan la probabilidad de abandono parcial.
- Segmentar clientes residenciales según comportamiento, servicios contratados y nivel de riesgo.
- Apoyar la toma de decisiones comerciales mediante modelos predictivos y descriptivos.
- Priorizar métricas como Recall, F1-Score y ROC-AUC, dado que no detectar a un cliente que efectivamente abandona puede ser más costoso que contactar preventivamente a un cliente que no iba a abandonar.

Para efectos del modelamiento supervisado, se utilizarán variables objetivo asociadas a los campos `ABANDONO_*`, evitando utilizar como predictores los campos `ABA_*`, ya que estos contienen información futura y podrían generar fuga de información en el modelo.

Hipótesis de Negocio

Hipótesis 1:

Los clientes residenciales con mayor cantidad de reclamos, exposición a fallas masivas o problemas técnicos presentan una mayor probabilidad de abandono parcial, debido a una menor percepción de calidad del servicio.

Hipótesis 2:

Los clientes residenciales con menor nivel de paquetización, menor antigüedad o menor cantidad de

servicios contratados presentan una mayor probabilidad de abandono parcial, ya que poseen una relación comercial menos consolidada con la empresa.

Fase 2: Comprensión de los Datos (Data Understanding)

En esta fase se realiza una exploración inicial del dataset con foco exclusivo en clientes del segmento **Residencial**. El objetivo es comprender la estructura de la base, revisar la variable objetivo, analizar la calidad de los datos y detectar patrones preliminares antes de tomar decisiones de preparación o modelamiento.

El análisis considera:

1. Carga del dataset y filtro del segmento residencial.
2. Revisión de volumen, tipos de datos y distribución de segmentos.
3. Validación de la variable objetivo `ABANDONO_FULL`.
4. Identificación de valores nulos, duplicados y variables constantes.
5. Revisión de distribuciones de variables numéricas críticas.
6. Detección preliminar de outliers mediante regla IQR y boxplots.
7. Análisis de correlación con la variable objetivo.
8. Revisión de correlaciones altas entre predictores numéricos.
9. Asociación inicial de variables categóricas con la tasa de abandono.
10. Identificación de posibles variables con fuga de información.

Este análisis servirá como base para definir qué variables conservar, transformar o excluir en la fase de preparación de datos.

RESUMEN GENERAL

	métrica	valor
0	Registros dataset original	180,275.0000
1	Columnas dataset original	84.0000
2	Registros segmento residencial	163,262.0000
3	Columnas segmento residencial	84.0000
4	Participación residencial	90.5600

DISTRIBUCIÓN POR SEGMENTO


	segmento	registros	porcentaje
0	RESIDENCIAL	163262	90.5600
1	NEGOCIOS	17013	9.4400

TIPOS DE DATOS EN SEGMENTO RESIDENCIAL

	tipo_dato	cantidad_variables
0	int64	42
1	str	27
2	float64	15

DISTRIBUCIÓN DE VARIABLE OBJETIVO

	ABANDONO_FULL	registros	porcentaje
0	0	157570	96.5100
1	1	5692	3.4900



RESUMEN DE CALIDAD

	métrica	valor
0	Duplicados completos	240
1	Variables con nulos	25
2	Variables constantes	10
3	Variables 100% nulas	4
4	Valores únicos en RUT_CLIENTE	1

VARIABLES CON MAYOR PORCENTAJE DE NULOS

	nulos	porcentaje_nulos
TASA_TRANSM_EQUIPO_24	163262	100.0000
RANK_EQUIPO	163262	100.0000
TASA_TRANSM_EQUIPO_50	163262	100.0000
LISTA_EQUIPOS	163262	100.0000
FECHA_CONTACTO	163247	99.9900
LISTA_CAUSAS_COMERCIAL_NO_TERRENO	157997	96.7800
LISTA_CAUSAS_TECNICO_TERRENO	134239	82.2200
LISTA_TIPO_RECLAMOS_TECNICO_TERRENO	134239	82.2200
LISTA_TIPO_RECLAMOS_TECNICO_NO_TERRENO	126189	77.2900
LISTA_CAUSAS_TECNICO_NO_TERRENO	126189	77.2900
LISTA_SS_SVA	124385	76.1900
NUM_RECLAMOS	106719	65.3700
MES_RECLAMO_MIN	106719	65.3700
MES_RECLAMO_MAX	106719	65.3700
NUM_RECLAMOS_TECNICO_TERRENO	106719	65.3700
COMUNA	7054	4.3200
CODIGO_INE_COMUNA	7054	4.3200
REGION	7054	4.3200
SUPERFICIE_KM2	7054	4.3200
LATITUD_DECIMAL	7054	4.3200
PROVINCIA	7054	4.3200
LONGITUD_DECIMAL	7054	4.3200
CONDICION_ESPECIAL	908	0.5600
VELOCIDAD_BAJADA	75	0.0500
VELOCIDAD_SUBIDA	75	0.0500

VARIABLES CONSTANTES

	variable
0	SEGMENTO
1	RUT_CLIENTE
2	FECHA
3	SS_SVATI
4	ABA_DATOS
5	TASA_TRANSM_EQUIPO_24
6	RANK_EQUIPO
7	TASA_TRANSM_EQUIPO_50
8	NOMB_RAZON
9	LISTA_EQUIPOS

VARIABLES 100% NULAS


	variable
0	TASA_TRANSM_EQUIPO_24
1	RANK_EQUIPO
2	TASA_TRANSM_EQUIPO_50
3	LISTA_EQUIPOS

RESUMEN ESTADÍSTICO DE VARIABLES NUMÉRICAS CRÍTICAS


	count	mean	std	min	25%	50%	75%	max
SS_INTE	163,262.0000	1.0613	0.2796	1.0000	1.0000	1.0000	1.0000	24.0000
SS_TV	163,262.0000	0.5506	0.5419	0.0000	0.0000	1.0000	1.0000	11.0000
SS_TEL	163,262.0000	0.2258	0.4378	0.0000	0.0000	0.0000	0.0000	10.0000
SS_SVA	163,262.0000	0.2627	0.5005	0.0000	0.0000	0.0000	0.0000	8.0000
SS_MOVIL	163,262.0000	0.0048	0.0901	0.0000	0.0000	0.0000	0.0000	12.0000
SS_DATOS	163,262.0000	0.0001	0.0102	0.0000	0.0000	0.0000	0.0000	2.0000
SS_TV_APP	163,262.0000	0.0415	0.2014	0.0000	0.0000	0.0000	0.0000	3.0000
ANTG_MESES_TODO	163,262.0000	86.4936	85.0203	0.0000	28.0000	59.0000	118.0000	471.0000
MONTO_POR_SS	163,262.0000	19,504.7523	6,736.0338	126.0000	14,822.7841	18,437.6667	23,547.6818	261.0000
VLOR_NETO_PROM	163,262.0000	34,062.7340	15,644.7285	252.0000	24,047.2955	30,815.1818	40,531.3864	415.0000
MESES_COBROS	163,262.0000	10.5251	1.6598	1.0000	11.0000	11.0000	11.0000	11.0000
VELOCIDAD_BAJADA	163,187.0000	823.3946	143.1992	0.0000	800.0000	900.0000	900.0000	2,000.0000
VELOCIDAD_SUBIDA	163,187.0000	614.1284	90.5967	0.0000	600.0000	600.0000	600.0000	2,000.0000
NUM_RECLAMOS	56,543.0000	1.7639	1.2966	1.0000	1.0000	1.0000	2.0000	38.0000
NUM_RECLAMOS_TECNICO_TERRENO	56,543.0000	0.6701	0.8138	0.0000	0.0000	1.0000	1.0000	10.0000
EVENTOS_DISTINTOS	163,262.0000	1.1157	0.8181	0.0000	1.0000	1.0000	1.0000	13.0000
HORAS_TOTALES_RUT	163,262.0000	6.4972	6.7331	0.0000	5.1700	5.1700	5.1700	224.0000
SUPERFICIE_KM2	156,208.0000	2,272.9926	4,699.8716	14.3000	464.0000	1,016.0000	1,748.2000	29,700.0000
LATITUD_DECIMAL	156,208.0000	-40.0858	2.6503	-47.2539	-41.4539	-39.8142	-38.7269	-33.0000
LONGITUD_DECIMAL	156,208.0000	-72.8445	0.5722	-73.9500	-73.1258	-72.9928	-72.5989	-70.0000




Distribución de SS_INTE




Distribución de SS_TV




Distribución de SS_TEL




Distribución de SS_SVA




Distribución de SS_MOVIL




Distribución de SS_DATOS




Distribución de SS_TV_APP




Distribución de ANTG_MESES_TODO




Distribución de MONTO_POR_SS




Distribución de VLOR_NETO_PROM




Distribución de MESES_COBROS




Distribución de VELOCIDAD_BAJADA




Distribución de VELOCIDAD_SUBIDA




Distribución de NUM_RECLAMOS




Distribución de NUM_RECLAMOS_TECNICO_TERRENO




Distribución de EVENTOS_DISTINTOS





Distribución de HORAS_TOTALES_RUT




Distribución de SUPERFICIE_KM2






RESUMEN DE OUTLIERS POR REGLA IQR


	variable	q1	q3	iqr	limite_inferior	limite_superior	outliers_iqr	porcent
3	SS_SVA	0.0000	0.0000	0.0000	0.0000	0.0000	38877	23.8100
2	SS_TEL	0.0000	0.0000	0.0000	0.0000	0.0000	35666	21.8500
11	VELOCIDAD_BAJADA	800.0000	900.0000	100.0000	650.0000	1,050.0000	35435	21.7100
16	HORAS_TOTALES_RUT	5.1700	5.1700	0.0000	5.1700	5.1700	32481	19.9000
15	EVENTOS_DISTINTOS	1.0000	1.0000	0.0000	1.0000	1.0000	32077	19.6500
17	SUPERFICIE_KM2	464.0000	1,748.2000	1,284.2000	-1,462.3000	3,674.5000	20137	12.8900
12	VELOCIDAD_SUBIDA	600.0000	600.0000	0.0000	600.0000	600.0000	18650	11.4300
10	MESES_COBROS	11.0000	11.0000	0.0000	11.0000	11.0000	16516	10.1200
18	LATITUD_DECIMAL	-41.4539	-38.7269	2.7270	-45.5444	-34.6364	13167	8.4300
13	NUM_RECLAMOS	1.0000	2.0000	1.0000	-0.5000	3.5000	4744	8.3900
7	ANTG_MESES_TODO	28.0000	118.0000	90.0000	-107.0000	253.0000	8982	5.5000
0	SS_INTE	1.0000	1.0000	0.0000	1.0000	1.0000	8921	5.4600
6	SS_TV_APP	0.0000	0.0000	0.0000	0.0000	0.0000	6719	4.1200
19	LONGITUD_DECIMAL	-73.1258	-72.5989	0.5269	-73.9161	-71.8085	6124	3.9200
9	VLOR_NETO_PROM	24,047.2955	40,531.3864	16,484.0909	-678.8409	65,257.5227	6334	3.8800
14	NUM_RECLAMOS_TECNICO_TERRENO	0.0000	1.0000	1.0000	-1.5000	2.5000	1640	2.9000
8	MONTO_POR_SS	14,822.7841	23,547.6818	8,724.8977	1,735.4375	36,635.0284	2490	1.5300
4	SS_MOVIL	0.0000	0.0000	0.0000	0.0000	0.0000	623	0.3800
1	SS_TV	0.0000	1.0000	1.0000	-1.5000	2.5000	215	0.1300
5	SS_DATOS	0.0000	0.0000	0.0000	0.0000	0.0000	11	0.0100




Boxplot de SS_INTE




Boxplot de SS_TV




Boxplot de SS_TEL




Boxplot de SS_SVA




Boxplot de SS_MOVIL




Boxplot de SS_DATOS




Boxplot de SS_TV_APP




Boxplot de ANTG_MESES_TODO




Boxplot de MONTO_POR_SS




Boxplot de VLOR_NETO_PROM




Boxplot de MESES_COBROS




Boxplot de VELOCIDAD_BAJADA




Boxplot de VELOCIDAD_SUBIDA




Boxplot de NUM_RECLAMOS




Boxplot de NUM_RECLAMOS_TECNICO_TERRENO




Boxplot de EVENTOS_DISTINTOS




Boxplot de HORAS_TOTALES_RUT




Boxplot de SUPERFICIE_KM2



Boxplot de LATITUD_DECIMAL






VALIDACIÓN DE VARIABLES ABANDONO_FULL POR SERVICIO

	servicio	variable_servicio	variable_abandono_full	clientes_sin_servicio	sin_servicio_marcados_full	porcentaje_sin_servicio_marcado_full
0	Internet	SS_INTE	ABANDONO_FULL_INTE	0	0	0.0000
1	TV	SS_TV	ABANDONO_FULL_TV	76789	76789	100.0000
2	Telefonía	SS_TEL	ABANDONO_FULL_TEL	127596	127596	100.0000
3	TV App	SS_TV_APP	ABANDONO_FULL_TV_APP	156543	156543	100.0000
4	SVA	SS_SVA	ABANDONO_FULL_SVA	124385	124385	100.0000

TOP 20 VARIABLES NUMÉRICAS MÁS CORRELACIONADAS CON ABANDONO_FULL

	variable	correlacion_con_abandono	correlacion_abs
0	ABANDONO_FULL_INTE	0.9024	0.9024
1	ABANDONO_INTE	0.8781	0.8781
2	ABANDONO_TEL	0.8781	0.8781
3	ABA_INTE	0.8724	0.8724
4	ABANDONO_TV	0.5632	0.5632
5	ABA_TV	0.5586	0.5586
6	ABANDONO_SVA	0.2548	0.2548
7	ABA_SVA	0.2486	0.2486
8	ABA_TEL	0.2451	0.2451
9	ABA_TV_APP	0.2314	0.2314
10	ABANDONO_TV_APP	0.2313	0.2313
11	ABANDONO_FULL_TV	0.1896	0.1896
12	ABANDONO_FULL_TEL	0.0957	0.0957
13	ABANDONO_FULL_SVA	0.0642	0.0642
14	ANTG_MESES_TODO	-0.0555	0.0555
15	VLOR_NETO_PROM	-0.0498	0.0498
16	TNT_SPORT_VIGENTE	-0.0478	0.0478
17	SS_TEL	-0.0463	0.0463
18	SS_TV	-0.0384	0.0384
19	ABANDONO_FULL_TV_APP	0.0353	0.0353



PARES DE VARIABLES NUMÉRICAS CON CORRELACIÓN ALTA ≥ 0.80

	variable_1	variable_2	correlacion_abs
1045	OFFICE	OFFICE_VIGENTE	0.9364
921	EVENTOS_DISTINTOS	HORAS_TOTALES_RUT	0.8248

RESUMEN DE ASOCIACIÓN CATEGÓRICA CON ABANDONO

	variable	categorias	registros_categoria_min	registros_categoria_max	tasa_abandono_min	tasa_abandono_max	rango_tasa
3	CODI_LOCALIDA	154	1	15196	0.0000	33.3300	33.3300
1	CRUCE_ACTIVO	7	2	65420	0.0000	20.0000	20.0000
6	COMUNA	88	1	15680	0.0000	13.0400	13.0400
7	PROVINCIA	18	99	25458	1.0100	4.6200	3.6100
8	REGION	9	99	55387	1.0100	4.1400	3.1300
2	CODI_ADMZONAL	12	3094	26600	1.9500	4.2900	2.3400
5	PRIORITARIO	2	95	163167	3.4900	5.2600	1.7700
0	EMPRESA	2	14457	148805	2.4300	3.5900	1.1600
4	CONDICION_ESPECIAL	2	908	162354	3.4800	4.0700	0.5900



TASA DE ABANDONO POR EMPRESA

	EMPRESA	registros	tasa_abandono
0	TELCOM	148805	3.5900
1	TELCOM_AYSEN	14457	2.4300

TASA DE ABANDONO POR CRUCE_ACTIVO

	CRUCE_ACTIVO	registros	tasa_abandono
1	BA+DATOS	5	20.0000
0	BA	65420	4.0300
2	BA+TV	62167	3.8300
4	VOZ+BA	5874	2.7900
5	VOZ+BA+TV	29790	1.7100
3	BA+TV+DATOS	4	0.0000
6	VOZ+BA+TV+DATOS	2	0.0000

TASA DE ABANDONO POR CODI_ADMZONAL

	CODI_ADMZONAL	registros	tasa_abandono
9	TMCO	20051	4.2900
5	OSRN	17445	4.2400
4	LANG	5436	4.1200
6	PMTT	26600	4.0400
8	TLCA	4290	3.9900
2	CNCP	23124	3.8700
1	CHLL	4834	3.4500
7	RNGA	3094	3.3300
10	VLDV	21186	2.8700
11	VLRC	7441	2.6900
3	CYHQ	14457	2.4300
0	CHLE	15304	1.9500

TASA DE ABANDONO POR CODI_LOCALIDA

	CODI_LOCALIDA	registros	tasa_abandono
19	CNCR	3	33.3300
11	CHCO	4	25.0000
90	PCHI	5	20.0000
75	MLFQ	22	18.1800
84	NNCL	7	14.2900
51	GRNR	23	13.0400
142	TJRL	26	11.5400
28	CRHE	11	9.0900
69	LOTA	12	8.3300
105	PQNC	13	7.6900
95	PILL	248	7.2600
108	PRGA	43	6.9800
118	QEPE	29	6.9000
27	CRCT	439	6.3800
137	STCR	65	6.1500

TASA DE ABANDONO POR CONDICION_ESPECIAL

	CONDICION_ESPECIAL	registros	tasa_abandono
1	SIN_INFORMAR	908	4.0700
0	N	162354	3.4800

TASA DE ABANDONO POR PRIORITARIO

	PRIORITARIO	registros	tasa_abandono
1	S	95	5.2600
0	N	163167	3.4900

TASA DE ABANDONO POR COMUNA

	COMUNA	registros	tasa_abandono
28	GRANEROS	23	13.0400
68	RENAICO	30	10.0000
41	LOTA	12	8.3300
52	PERQUENCO	13	7.6900
18	CURACAUTIN	439	6.3800
60	PUQUELDON	85	5.8800
58	PUERTO OCTAY	86	5.8100
2	ANGOL	1788	5.4800
35	LAUTARO	1336	5.3900
27	GORBEA	169	5.3300
4	CARAHUE	19	5.2600
39	LOS LAGOS	605	5.1200
23	FRUTILLAR	1150	4.6100
47	OSORNO	10593	4.5600
57	PUERTO MONTT	15430	4.4500

TASA DE ABANDONO POR PROVINCIA

	PROVINCIA	registros	tasa_abandono
10	Malleco	3227	4.6200
11	Osorno	13483	4.2900
16	Talca	2342	4.1400
1	Bio Bio	5421	4.1300
9	Llanquihue	25458	4.1000
13	Ranco	4539	3.9000
6	Concepción	23134	3.8700
4	Cautín	23966	3.7600
14	SIN_INFORMAR	7054	3.6100
2	Cachapoal	3027	3.2700
7	Coyhaique	8968	3.1900
17	Valdivia	20609	2.8700
12	Palena	1142	2.6300
5	Chiloé	15304	1.9500
8	General Carrera	608	1.3200

TASA DE ABANDONO POR REGION

	REGION	registros	tasa_abandono
6	Maule	2342	4.1400
1	Bio Bio	28555	3.9200
2	La Araucanía	27193	3.8600
8	SIN_INFORMAR	7054	3.6100
4	Los Lagos	55387	3.5200
3	Lib. Gral. Bernardo O' Higgins	3027	3.2700
5	Los Ríos	25148	3.0500
0	Aysén del Gral. C.Ibáñez del Campo	14457	2.4300
7	Metropolitana de Santiago	99	1.0100

RESUMEN DE POSIBLE FUGA DE INFORMACIÓN

	grupo	cantidad	variables	criterio
0	Variables ABA_*	7	[ABA_INTE, ABA_SVA, ABA_TEL, ABA_TV, ABA_MOVIL...	Excluir por contener información po:
1	Variables ABANDONO_* distintas del target	10	[ABANDONO_FULL_INTE, ABANDONO_INTE, ABANDONO_F...	Excluir como predictores para evitar
2	Gestión comercial	4	[ESTADO_CONTACTO, FIDELIZADO, DERIVADO_A_EJECU...	Revisar temporalidad; excluir si corre




Matriz de correlación de variables numéricas críticas

Se calcula una matriz de correlación entre las variables numéricas críticas revisadas en el análisis exploratorio. Esta matriz permite observar relaciones lineales entre variables de servicios contratados, antigüedad, facturación, reclamos, eventos técnicos, ubicación geográfica y la variable objetivo **ABANDONO_FULL** .

El objetivo de esta revisión es identificar patrones de asociación relevantes y detectar posibles redundancias entre predictores antes de la preparación final y el modelamiento.

MATRIZ DE CORRELACIÓN - VARIABLES NUMÉRICAS CRÍTICAS

	ABANDONO_FULL	SS_INTE	SS_TV	SS_TEL	SS_SVA	SS_MOVIL	SS_DATOS
ABANDONO_FULL	1.0000	-0.0204	-0.0384	-0.0463	-0.0133	-0.0086	0.0018
SS_INTE	-0.0204	1.0000	0.2044	0.1165	0.1594	0.0450	0.0155
SS_TV	-0.0384	0.2044	1.0000	0.3163	0.1683	0.0369	-0.0013
SS_TEL	-0.0463	0.1165	0.3163	1.0000	0.0865	0.0639	0.0001
SS_SVA	-0.0133	0.1594	0.1683	0.0865	1.0000	0.0362	0.0019
SS_MOVIL	-0.0086	0.0450	0.0369	0.0639	0.0362	1.0000	0.0129
SS_DATOS	0.0018	0.0155	-0.0013	0.0001	0.0019	0.0129	1.0000
SS_TV_APP	0.0336	0.0416	-0.1328	-0.0486	-0.0567	0.0255	0.0103
ANTG_MESES_TODO	-0.0555	0.0963	0.2772	0.5943	0.1129	0.0628	0.0072
MONTO_POR_SS	-0.0076	-0.0245	-0.3466	-0.3848	0.1565	-0.0511	-0.0025
VLOR_NETO_PROM	-0.0498	0.5100	0.6049	0.3679	0.3225	0.0877	0.0174
MESES_COBROS	-0.0319	0.0502	0.2700	0.1283	0.1380	0.0123	0.0015
VELOCIDAD_BAJADA	-0.0286	0.0680	0.1935	0.0985	0.1724	0.0131	-0.0004
VELOCIDAD_SUBIDA	0.0118	0.0408	-0.1644	-0.1051	-0.1009	-0.0090	0.0055
NUM_RECLAMOS	-0.0084	0.0922	0.1289	0.0956	0.0464	0.0166	-0.0017
NUM_RECLAMOS_TECNICO_TERRENO	0.0005	0.0304	-0.0195	0.0023	0.0078	0.0045	0.0018
EVENTOS_DISTINTOS	-0.0109	0.0265	0.0189	0.0139	0.0125	-0.0022	-0.0011
HORAS_TOTALES_RUT	-0.0099	0.0260	0.0058	0.0028	0.0091	-0.0042	-0.0015
SUPERFICIE_KM2	-0.0217	0.0340	-0.0337	-0.0785	0.0319	-0.0139	-0.0014
LATITUD_DECIMAL	0.0223	-0.0610	0.0701	0.0509	-0.0278	0.0042	-0.0015
LONGITUD_DECIMAL	0.0087	-0.0121	-0.0166	-0.0927	-0.0054	-0.0225	-0.0043



TOP 20 PARES DE VARIABLES NUMÉRICAS CRÍTICAS MÁS CORRELACIONADAS

	variable_1	variable_2	correlacion	correlacion_abs
353	EVENTOS_DISTINTOS	HORAS_TOTALES_RUT	0.8248	0.8248
52	SS_TV	VLOR_NETO_PROM	0.6049	0.6049
71	SS_TEL	ANTG_MESES_TODO	0.5943	0.5943
397	SUPERFICIE_KM2	LATITUD_DECIMAL	-0.5500	0.5500
31	SS_INTE	VLOR_NETO_PROM	0.5100	0.5100
72	SS_TEL	MONTO_POR_SS	-0.3848	0.3848
73	SS_TEL	VLOR_NETO_PROM	0.3679	0.3679
265	VELOCIDAD_BAJADA	VELOCIDAD_SUBIDA	0.3643	0.3643
51	SS_TV	MONTO_POR_SS	-0.3466	0.3466
94	SS_SVA	VLOR_NETO_PROM	0.3225	0.3225
45	SS_TV	SS_TEL	0.3163	0.3163
309	NUM_RECLAMOS	NUM_RECLAMOS_TECNICO_TERRENO	0.3049	0.3049
178	ANTG_MESES_TODO	VLOR_NETO_PROM	0.2776	0.2776
50	SS_TV	ANTG_MESES_TODO	0.2772	0.2772
53	SS_TV	MESES_COBROS	0.2700	0.2700
244	MESES_COBROS	VELOCIDAD_SUBIDA	-0.2580	0.2580
179	ANTG_MESES_TODO	MESES_COBROS	0.2518	0.2518
221	VLOR_NETO_PROM	MESES_COBROS	0.2452	0.2452
199	MONTO_POR_SS	VLOR_NETO_PROM	0.2440	0.2440
222	VLOR_NETO_PROM	VELOCIDAD_BAJADA	0.2224	0.2224

Interpretación de la matriz de correlación

La matriz de correlación entre variables numéricas críticas muestra que las variables conservadas para el análisis exploratorio no presentan una relación lineal fuerte con `ABANDONO_FULL`. Las correlaciones más altas con la variable objetivo son bajas en magnitud: `ANTG_MESES_TODO` presenta una correlación negativa de **-0,0555**, `VLOR_NETO_PROM` de **-0,0498**, `SS_TEL` de **-0,0463**, `SS_TV` de **-0,0384** y `SS_TV_APP` una correlación positiva de **0,0336**.

Esto indica que el abandono no parece estar explicado por una sola variable numérica de forma lineal. Por lo tanto, el modelamiento posterior deberá considerar combinaciones de variables, interacciones, variables categóricas y posibles relaciones no lineales. También refuerza la importancia de no depender únicamente de correlaciones simples para seleccionar predictores.

En cuanto a la relación entre predictores, el par con mayor correlación corresponde a `EVENTOS_DISTINTOS` y `HORAS_TOTALES_RUT`, con una correlación de **0,8248**. Esta relación es esperable, ya que una mayor cantidad de eventos técnicos tiende a estar asociada a más horas acumuladas de afectación. Dado que supera el umbral de 0,80, estas variables podrían considerarse parcialmente redundantes. En modelos lineales convendría evaluar conservar solo una de ellas o revisar su impacto; en modelos basados en árboles podrían mantenerse inicialmente.

También se observan correlaciones moderadas entre variables de servicios y facturación. `SS_TV` y `VLOR_NETO_PROM` presentan una correlación de **0,6049**, `SS_TEL` y `ANTG_MESES_TODO` de **0,5943**, y `SS_INTE` con `VLOR_NETO_PROM` de **0,5100**. Estas relaciones son coherentes con el negocio, ya que una mayor cantidad de servicios contratados o una mayor antigüedad pueden estar asociadas a mayores niveles de facturación promedio.

La variable geográfica `SUPERFICIE_KM2` presenta una correlación negativa moderada con `LATITUD_DECIMAL` de **-0,5500**, lo que refleja una relación territorial propia de las comunas consideradas en la zona de análisis. Esta correlación no implica causalidad, pero sugiere que las variables geográficas podrían aportar información contextual relevante.

En general, salvo el par `EVENTOS_DISTINTOS` y `HORAS_TOTALES_RUT`, no se observan correlaciones extremadamente altas entre predictores numéricos críticos. Esto sugiere que no existe multicolinealidad severa generalizada dentro del conjunto revisado. Sin embargo, las correlaciones moderadas entre servicios, facturación, antigüedad y variables geográficas deberán considerarse en la preparación final y en la interpretación de modelos.

Un punto importante es que las variables numéricas críticas muestran baja correlación directa con `ABANDONO_FULL`, mientras que en el análisis previo las variables `ABA_*` y algunas variables `ABANDONO_*` distintas del target aparecían fuertemente correlacionadas con la variable objetivo. Esto

confirma que dichas variables contienen información demasiado cercana al evento de abandono y deben excluirse del modelamiento para evitar fuga de información.

Decisiones derivadas del análisis de correlación

A partir del análisis de correlación se definen los siguientes criterios para la fase de preparación:

- Mantener inicialmente las variables numéricas críticas, ya que no presentan multicolinealidad severa generalizada.
- Revisar el par `EVENTOS_DISTINTOS` y `HORAS_TOTALES_RUT`, dado que presenta correlación alta. Para modelos lineales podría conservarse solo una de ellas o evaluar su efecto en el desempeño.
- No eliminar variables únicamente por baja correlación con `ABANDONO_FULL`, ya que el abandono puede depender de relaciones no lineales, combinaciones de variables o variables categóricas.
- Excluir variables `ABA_*` y variables `ABANDONO_*` distintas de `ABANDONO_FULL`, porque su alta asociación con el target responde a fuga de información y no a capacidad predictiva legítima.
- Mantener variables comerciales, técnicas, geográficas y de servicios para la preparación final, priorizando una limpieza cuidadosa antes del modelamiento.

Fase 3: Preparación de los Datos (Data Preparation)

A partir de los hallazgos de la fase exploratoria, se prepara el dataset para análisis avanzado y modelamiento predictivo. Esta etapa busca construir una base limpia, consistente y sin fuga de información, manteniendo variables comerciales, técnicas, geográficas y de servicios que puedan aportar señal para anticipar abandono residencial.

Las principales decisiones de preparación son:

1. Eliminar duplicados completos.
2. Excluir variables constantes, completamente nulas o no informativas.
3. Excluir variables `ABA_*` y variables `ABANDONO_*` distintas de `ABANDONO_FULL`, para evitar fuga de información.
4. Excluir variables de gestión comercial con temporalidad ambigua, como `FIDELIZADO`, `ESTADO_CONTACTO`, `DERIVADO_A_EJECUTIVO` y `FECHA_CONTACTO`.
5. Reemplazar campos tipo lista por variables binarias `FLAG_*`, conservando la señal de existencia de registros sin introducir alta cardinalidad.
6. Imputar valores nulos según el tipo de variable.
7. Mantener outliers como observaciones válidas, dado que en su mayoría corresponden a fenómenos reales del negocio, como diferencias de facturación, antigüedad, reclamos, velocidad o ubicación.
8. Generar el dataset preparado para modelamiento, separando predictores y variable objetivo.

RESUMEN DE PREPARACIÓN

	métrica	valor
0	Registros iniciales residenciales	163,262.0000
1	Duplicados completos eliminados	240.0000
2	Registros finales preparados	163,022.0000
3	Columnas iniciales	84.0000
4	Columnas excluidas	40.0000
5	Columnas finales incluyendo target	53.0000
6	Variables predictoras finales	52.0000
7	Variables numéricas predictoras	43.0000
8	Variables categóricas predictoras	9.0000
9	Nulos restantes en dataset preparado	0.0000
10	Casos positivos target	5,691.0000
11	Porcentaje positivo target	3.4900
12	Registros train	114,115.0000
13	Registros test	48,907.0000
14	Porcentaje positivo train	3.4900
15	Porcentaje positivo test	3.4900

CRITERIOS DE EXCLUSIÓN

	criterio	cantidad	columnas
0	Variables constantes	10	[SEGMENTO, RUT_CLIENTE, FECHA, SS_SVATI, ABA_D...
1	Variables 100% nulas	4	[TASA_TRANSM_EQUIPO_24, TASA_TRANSM_EQUIPO_50,...
2	Variables ABA_*	7	[ABA_INTE, ABA_SVA, ABA_TEL, ABA_TV, ABA_MOVIL...
3	Variables ABANDONO_* no target	10	[ABANDONO_FULL_INTE, ABANDONO_INTE, ABANDONO_F...
4	Identificación / no informativas	4	[RUT_CLIENTE, NOMB_RAZON, SEGMENTO, FECHA]
5	Fechas crudas	4	[FECH_ALTA, FECHA_MIN, MES_RECLAMO_MIN, MES_RE...
6	Gestión comercial con temporalidad ambigua	4	[ESTADO_CONTACTO, FIDELIZADO, DERIVADO_A_EJECU...
7	Listas originales reemplazadas por flags	6	[LISTA_SS_SVA, LISTA_CAUSAS_COMERCIAL_NO_TERRE...

DISTRIBUCIÓN TRAIN / TEST

	partición	registros	positivos	porcentaje_positivos
0	Train	114115	3984	3.4900
1	Test	48907	1707	3.4900

COLUMNAS FINALES DEL DATASET PREPARADO

	columna	tipo_dato
0	EMPRESA	str
1	SS_INTE	int64
2	SS_SVA	int64
3	SS_DATOS	int64
4	SS_TV	int64
5	SS_MOVIL	int64
6	SS_TV_APP	int64
7	SS_TEL	int64
8	CRUCE_ACTIVO	str
9	ANTG_MESES_TODO	int64
10	LOCALIDADES_DISTINTAS	int64
11	CODI_ADMZONAL	str
12	CODI_LOCALIDA	str
13	MONTO_POR_SS	float64
14	VELOCIDAD_SUBIDA	float64
15	ABANDONO_FULL	int64
16	TELEVIGILANCIA	int64
17	VELOCIDAD_BAJADA	float64
18	CONDICION_ESPECIAL	str
19	PRIORITARIO	str
20	VLOR_NETO_PROM	float64
21	MESES_COBROS	int64
22	NUM_IDEN_GRUPOFAC	int64
23	NUM_RECLAMOS_TECNICO_TERRENO	float64
24	NUM_RECLAMOS	float64
25	EVENTOS_DISTINTOS	int64
26	HORAS_TOTALES_RUT	float64
27	FOX_SPORT	int64
28	OFFICE	int64
29	PLAN_HBO	int64
30	PROVEEDOR_FINAL_ALARMCOM	int64
31	TNT_SPORT	int64
32	FOX_SPORT_VIGENTE	int64
33	OFFICE_VIGENTE	int64
34	PLAN_HBO_VIGENTE	int64

	columna	tipo_dato
35	PROVEEDOR_FINAL_ALARMCOM_VIGENTE	int64
36	TNT_SPORT_VIGENTE	int64
37	CODIGO_INE_COMUNA	float64
38	COMUNA	str
39	PROVINCIA	str
40	REGION	str
41	SUPERFICIE_KM2	float64
42	LATITUD_DECIMAL	float64
43	LONGITUD_DECIMAL	float64
44	FLAG_LISTA_SS_SVA	int64
45	FLAG_LISTA_CAUSAS_COMERCIAL_NO_TERRENO	int64
46	FLAG_LISTA_CAUSAS_TECNICO_NO_TERRENO	int64
47	FLAG_LISTA_CAUSAS_TECNICO_TERRENO	int64
48	FLAG_LISTA_TIPO_RECLAMOS_TECNICO_NO_TERRENO	int64
49	FLAG_LISTA_TIPO_RECLAMOS_TECNICO_TERRENO	int64
50	FLAG_TIENE_RECLAMOS	int64
51	FLAG_TIENE_EVENTOS_TECNICOS	int64
52	TOTAL_SERVICIOS	int64

Tratamiento de variables categóricas y numéricas

En esta fase las variables categóricas se conservan como texto dentro del dataset preparado, ya que su transformación se realizará posteriormente dentro del pipeline de modelamiento. Esto evita aplicar transformaciones manuales antes de la partición train-test y reduce el riesgo de fuga de información.

Durante el modelamiento, las variables categóricas serán codificadas mediante `OneHotEncoder`, generando variables binarias para cada categoría. Las variables numéricas serán escaladas mediante `StandardScaler` cuando el algoritmo lo requiera, especialmente en modelos sensibles a escala como Regresión Logística o SVM.

Las variables categóricas finales del dataset preparado son `EMPRESA`, `CRUCE_ACTIVO`, `CODI_ADMZONAL`, `CODI_LOCALIDA`, `CONDICION_ESPECIAL`, `PRIORITARIO`, `COMUNA`, `PROVINCIA` y `REGION`. Estas variables serán tratadas como predictores categóricos en el pipeline.

Interpretación de la preparación de datos

La preparación de datos se realizó sobre la base residencial, compuesta inicialmente por **163.262 registros**. Se eliminaron **240 duplicados completos**, quedando un dataset preparado con **163.022 registros**.

A partir de los criterios definidos en la fase exploratoria, se excluyeron **40 columnas**. Esta exclusión consideró variables constantes, columnas completamente nulas, variables `ABA_*`, variables `ABANDONO_*` distintas de `ABANDONO_FULL`, identificadores no informativos, fechas crudas, variables de gestión comercial con temporalidad ambigua y listas originales de alta cardinalidad.

El dataset final quedó compuesto por **53 columnas**, incluyendo la variable objetivo, y **52 variables predictoras**. De estas, **43 son numéricas** y **9 son categóricas**. Las variables categóricas se conservarán como texto en esta fase y serán transformadas posteriormente mediante `OneHotEncoder` dentro del pipeline de modelamiento.

Los valores nulos fueron tratados completamente, quedando **0 valores faltantes** en el dataset preparado. En variables numéricas se aplicó imputación estadística, mientras que en variables categóricas se utilizó una categoría explícita para representar ausencia de información.

Las variables tipo lista asociadas a servicios adicionales, causas de reclamo y tipos de reclamo fueron reemplazadas por indicadores binarios `FLAG_*`. Esta decisión permite conservar la señal de existencia de registros relevantes sin introducir campos textuales de alta cardinalidad.

La variable objetivo `ABANDONO_FULL` mantiene **5.691 casos positivos**, equivalentes al **3,49%** del dataset preparado. Esto confirma que el problema sigue siendo una clasificación desbalanceada y que el modelamiento deberá priorizar métricas como Recall, F1-Score, ROC-AUC y PR-AUC.

Finalmente, se generó una partición estratificada entre entrenamiento y prueba. El conjunto de entrenamiento quedó compuesto por **114.115 registros**, con **3.984 casos positivos**, mientras que el conjunto de prueba quedó compuesto por **48.907 registros**, con **1.707 casos positivos**. En ambos conjuntos se mantiene una proporción de abandono de **3,49%**, lo que permite evaluar los modelos de forma consistente.

Fase 4: Modelamiento

En esta fase se aplican modelos supervisados y no supervisados sobre el dataset preparado de clientes residenciales. El objetivo es abordar el problema desde tres enfoques complementarios:

1. **Aprendizaje supervisado:** predecir la probabilidad de abandono mediante modelos de clasificación.
2. **Aprendizaje no supervisado:** segmentar clientes según características comerciales, técnicas, geográficas y de servicios.
3. **Reglas de asociación:** descubrir patrones de contratación conjunta de servicios que puedan apoyar estrategias de retención y venta cruzada.

Para el aprendizaje supervisado se utiliza como variable objetivo `ABANDONO_FULL`. Dado que la clase positiva representa aproximadamente el **3,49%** de los registros, se considera un problema de clasificación desbalanceada. Por ello, la evaluación prioriza métricas como `Recall`, `Precision`, `F1-Score`, `ROC-AUC` y `PR-AUC`, además de analizar la matriz de confusión desde una perspectiva de negocio.

Las variables numéricas son escaladas mediante `StandardScaler` o `MinMaxScaler`, según el modelo, y las variables categóricas son transformadas mediante `OneHotEncoder`. Estas transformaciones se aplican dentro de pipelines para evitar fuga de información.

Los modelos supervisados evaluados son:

- Regresión Logística balanceada.
- Árbol de Decisión balanceado.
- Naive Bayes.
- SVM lineal balanceado como modelo adicional investigado.

Para el aprendizaje no supervisado se aplican:

- K-Means.
- Clustering Jerárquico sobre una muestra representativa, debido al tamaño de la base.

Finalmente, se aplican reglas de asociación tipo Apriori sobre variables de servicios contratados y servicios vigentes, con el objetivo de identificar combinaciones de servicios que puedan actuar como anclas de fidelización.

RESUMEN DEL SET DE MODELAMIENTO

	métrica	valor
0	Registros entrenamiento	114,115.0000
1	Registros prueba	48,907.0000
2	Variables predictoras originales	52.0000
3	Variables numéricas	43.0000
4	Variables categóricas	9.0000
5	Casos positivos train	3,984.0000
6	Casos positivos test	1,707.0000
7	Porcentaje abandono train	3.4900
8	Porcentaje abandono test	3.4900

RESULTADOS COMPARATIVOS - MODELOS SUPERVISADOS

	modelo	accuracy	precision	recall	f1_score	roc_auc	pr_auc	tn	
0	Regresión logística balanceada	0.5256	0.0515	0.7235	0.0962	0.6683	0.0629	24469	
3	SVM lineal balanceado	0.5210	0.0515	0.7299	0.0961	0.6681	0.0627	24235	
1	Árbol de decisión balanceado	0.4447	0.0467	0.7686	0.0881	0.6390	0.0536	20438	
2	Naive Bayes	0.9646	0.0714	0.0012	0.0023	0.6353	0.0510	47174	



MEJOR MODELO SUPERVISADO SEGÚN F1-SCORE: Regresión logística balanceada

precisionrecallf1-score support

No abandono0.980.520.6847200

Abandono0.050.720.101707

accuracy0.5348907

macro avg0.520.620.3948907

weighted avg0.950.530.6648907

MATRIZ DE CONFUSIÓN DEL MEJOR MODELO SUPERVISADO

	Predicho no abandono	Predicho abandono
Real no abandono	24469	22731
Real abandono	472	1235

TOP 20 VARIABLES MÁS IMPORTANTES SEGÚN ÁRBOL DE DECISIÓN

	variable	importancia
29	TNT_SPORT_VIGENTE	0.3515
7	ANTG_MESES_TODO	0.2241
32	LATITUD_DECIMAL	0.1137
13	VLOR_NETO_PROM	0.0671
50	CRUCE_ACTIVO_VOZ+BA+TV	0.0632
33	LONGITUD_DECIMAL	0.0419
5	SS_TV_APP	0.0358
63	CODI_ADMZONAL_VLRC	0.0243
0	SS_INTE	0.0151
30	CODIGO_INE_COMUNA	0.0143
238	COMUNA_COYHAIQUE	0.0129
42	TOTAL_SERVICIOS	0.0122
9	MONTO_POR_SS	0.0110
18	EVENTOS_DISTINTOS	0.0065
31	SUPERFICIE_KM2	0.0062
310	PROVINCIA_Aysén	0.0000
311	PROVINCIA_Bio Bio	0.0000
312	PROVINCIA_Cachapoal	0.0000
313	PROVINCIA_Capitán Prat	0.0000
314	PROVINCIA_Cautín	0.0000

VARIABLES USADAS EN MODELOS NO SUPERVISADOS

	tipo	cantidad
0	numéricas	22
1	categorías	5
2	total originales	27

EVALUACIÓN DE K - K-MEANS

	modelo	k	inertia	silhouette_sample
0	K-Means	2	3,705,710.9002	0.1263
1	K-Means	3	3,456,575.8465	0.1319
2	K-Means	4	3,357,522.2584	0.0830
3	K-Means	5	3,101,590.0498	0.1079
4	K-Means	6	3,006,793.4271	0.1088
5	K-Means	7	2,912,328.3410	0.1112

K ÓPTIMO K-MEANS SEGÚN SILHOUETTE: 3
PERFIL GENERAL DE CLUSTERS - K-MEANS

	CLUSTER_KMEANS	clientes	abandonos	tasa_abandono	total_servicios_prom	antiguedad_prom	monto_por_ss_prom	valor_u
0	0	61337	2607	4.2500	1.2647	50.7319	22,997.0689	24,596
2	2	12664	495	3.9100	1.7063	60.3033	19,336.9606	28,312
1	1	89021	2589	2.9100	2.8201	115.0485	17,124.3598	41,442



EVALUACIÓN DE K - CLUSTERING JERÁRQUICO

	modelo	k	silhouette_sample
0	Clustering Jerárquico	2	0.1375
1	Clustering Jerárquico	3	0.1467
2	Clustering Jerárquico	4	0.0817
3	Clustering Jerárquico	5	0.1022
4	Clustering Jerárquico	6	0.1173
5	Clustering Jerárquico	7	0.1233

K ÓPTIMO CLUSTERING JERÁRQUICO SEGÚN SILHOUETTE: 3
PERFIL GENERAL DE CLUSTERS - CLUSTERING JERÁRQUICO

	CLUSTER_JERARQUICO	clientes	abandonos	tasa_abandono	total_servicios_prom	antiguedad_prom	monto_por_ss_prom	va
2	2	1126	52	4.6200	1.8996	58.7940	19,212.4974	30
0	0	5195	206	3.9700	1.7702	64.0922	20,859.9671	30
1	1	1679	33	1.9700	3.4675	169.7290	15,301.9545	46



COMPARACIÓN DE MODELOS NO SUPERVISADOS

	modelo	base	k_optimo	silhouette	observacion
0	K-Means	dataset completo	3	0.1319	Segmentación escalable sobre toda la base
1	Clustering Jerárquico	muestra de 8000 registros	3	0.1467	Segmentación exploratoria por costo computacional

FRECUENCIA DE ITEMS DE SERVICIOS

	item	frecuencia
0	INTERNET	1.0000
1	TV	0.5304
2	SVA	0.2384
3	TELEFONIA	0.2188
4	TNT_SPORT	0.0599
5	TV_APP	0.0412
6	ALARMCOM	0.0106
7	OFFICE	0.0044
8	MOVIL	0.0038
9	PLAN_HBO	0.0030
10	FOX_SPORT	0.0016
11	DATOS	0.0001

ITEMSETS FRECUENTES - APRIORI

	itemset	tamaño	support
0	(INTERNET,)	1	1.0000
1	(TV,)	1	0.5304
2	(SVA,)	1	0.2384
3	(TELEFONIA,)	1	0.2188
4	(TNT_SPORT,)	1	0.0599
5	(TV_APP,)	1	0.0412
6	(ALARMCOM,)	1	0.0106
7	(INTERNET, TV)	2	0.5304
8	(INTERNET, SVA)	2	0.2384
9	(INTERNET, TELEFONIA)	2	0.2188
14	(TELEFONIA, TV)	2	0.1805
13	(SVA, TV)	2	0.1577
18	(SVA, TELEFONIA)	2	0.0648
10	(INTERNET, TNT_SPORT)	2	0.0599
15	(TNT_SPORT, TV)	2	0.0579
11	(INTERNET, TV_APP)	2	0.0412
21	(TELEFONIA, TNT_SPORT)	2	0.0253
19	(SVA, TNT_SPORT)	2	0.0195
12	(ALARMCOM, INTERNET)	2	0.0106
20	(ALARMCOM, SVA)	2	0.0106
16	(TV, TV_APP)	2	0.0075
17	(ALARMCOM, TV)	2	0.0068
23	(INTERNET, TELEFONIA, TV)	3	0.1805
22	(INTERNET, SVA, TV)	3	0.1577
27	(INTERNET, SVA, TELEFONIA)	3	0.0648
24	(INTERNET, TNT_SPORT, TV)	3	0.0579
31	(SVA, TELEFONIA, TV)	3	0.0540
30	(INTERNET, TELEFONIA, TNT_SPORT)	3	0.0253
34	(TELEFONIA, TNT_SPORT, TV)	3	0.0252
28	(INTERNET, SVA, TNT_SPORT)	3	0.0195

	antecedente	consecuente	support	confidence	lift	tasa_abandono_antecedente	tasa_abandono_
19	ALARMCOM	SVA	0.0106	1.0000	4.1940	0.5800	0.5800
50	ALARMCOM	INTERNET + SVA	0.0106	1.0000	4.1940	0.5800	0.5800
51	ALARMCOM + INTERNET	SVA	0.0106	1.0000	4.1940	0.5800	0.5800
66	ALARMCOM + TV	SVA	0.0068	1.0000	4.1940	0.3600	0.3600
64	ALARMCOM	SVA + TV	0.0068	0.6389	4.0520	0.5800	0.3600
67	TNT_SPORT	TELEFONIA + TV	0.0252	0.4203	2.3283	0.0100	0.0000
61	TNT_SPORT	SVA + TV	0.0194	0.3244	2.0572	0.0100	0.0000
69	TNT_SPORT + TV	TELEFONIA	0.0252	0.4342	1.9847	0.0000	0.0000
20	TNT_SPORT	TELEFONIA	0.0253	0.4230	1.9335	0.0100	0.0000
53	TNT_SPORT	INTERNET + TELEFONIA	0.0253	0.4230	1.9335	0.0100	0.0000
54	INTERNET + TNT_SPORT	TELEFONIA	0.0253	0.4230	1.9335	0.0100	0.0000
70	SVA + TNT_SPORT	TELEFONIA	0.0082	0.4175	1.9086	0.0000	0.0000
62	SVA + TNT_SPORT	TV	0.0194	0.9943	1.8748	0.0000	0.0000
68	TELEFONIA + TNT_SPORT	TV	0.0252	0.9937	1.8736	0.0000	0.0000
13	TNT_SPORT	TV	0.0579	0.9680	1.8252	0.0100	0.0000
33	TNT_SPORT	INTERNET + TV	0.0579	0.9680	1.8252	0.0100	0.0000
34	INTERNET + TNT_SPORT	TV	0.0579	0.9680	1.8252	0.0100	0.0000
58	SVA + TELEFONIA	TV	0.0540	0.8341	1.5727	1.8300	1.5800
59	SVA + TV	TELEFONIA	0.0540	0.3427	1.5666	2.7900	1.5800
57	TELEFONIA	SVA + TV	0.0540	0.2470	1.5666	1.8900	1.5800
11	TELEFONIA	TV	0.1805	0.8252	1.5558	1.8900	1.6800
28	TELEFONIA	INTERNET + TV	0.1805	0.8252	1.5558	1.8900	1.6800
30	INTERNET + TELEFONIA	TV	0.1805	0.8252	1.5558	1.8900	1.6800
12	TV	TELEFONIA	0.1805	0.3404	1.5558	2.8600	1.6800
29	TV	INTERNET + TELEFONIA	0.1805	0.3404	1.5558	2.8600	1.6800
31	INTERNET + TV	TELEFONIA	0.1805	0.3404	1.5558	2.8600	1.6800
63	TNT_SPORT + TV	SVA	0.0194	0.3351	1.4054	0.0000	0.0000
18	TNT_SPORT	SVA	0.0195	0.3262	1.3682	0.0100	0.0000
47	TNT_SPORT	INTERNET + SVA	0.0195	0.3262	1.3682	0.0100	0.0000
48	INTERNET + TNT_SPORT	SVA	0.0195	0.3262	1.3682	0.0100	0.0000



Interpretación de la Fase 4: Modelamiento

La fase de modelamiento incorporó tres enfoques complementarios: modelos supervisados para predecir abandono, modelos no supervisados para segmentar clientes y reglas de asociación para descubrir patrones de contratación conjunta de servicios.

En el bloque supervisado se evaluaron cuatro modelos: Regresión Logística balanceada, SVM lineal balanceado, Árbol de Decisión balanceado y Naive Bayes. El conjunto de entrenamiento tuvo **114.115 registros** y el conjunto de prueba **48.907 registros**, manteniendo en ambos casos una tasa de abandono de **3,49%**.

El mejor modelo según **F1-Score** fue la **Regresión Logística balanceada**, con un F1-Score de **0,0962**, Recall de **0,7235**, ROC-AUC de **0,6683** y PR-AUC de **0,0629**. Este modelo logró detectar **1.235 de los 1.707 abandonos reales** del conjunto de prueba. Si bien su precisión es baja, esto es esperable dado el fuerte desbalance de clases. Desde el punto de vista del negocio, el modelo resulta útil porque prioriza clientes en riesgo, aunque genera falsos positivos que deben ser controlados por el costo de campaña.

El SVM lineal obtuvo un desempeño muy similar, con Recall de **0,7299** y F1-Score de **0,0961**. El Árbol de Decisión alcanzó el mayor Recall, con **0,7686**, pero a costa de más falsos positivos y menor F1-Score. Naive Bayes obtuvo una Accuracy alta de **0,9646**, pero prácticamente no detectó abandonos reales, con un Recall de solo **0,0012**. Esto demuestra que Accuracy no es una métrica suficiente en problemas desbalanceados.

La matriz de confusión de la Regresión Logística muestra **472 falsos negativos** y **22.731 falsos positivos**. En el contexto de abandono de clientes, el falso negativo es más crítico, ya que implica no detectar a un cliente que efectivamente abandona. El falso positivo tiene un costo comercial asociado, pero puede ser tolerable si la campaña de retención es de bajo costo o no invasiva. Por ello, el modelo debe utilizarse como herramienta de priorización, no como regla automática de contacto masivo.

El Árbol de Decisión identificó como variables relevantes **TNT_SPORT_VIGENTE**, **ANTG_MESES_TODO**, **LATITUD_DECIMAL**, **VLOR_NETO_PROM**, **CRUCE_ACTIVO_VOZ+BA+TV**, **LONGITUD_DECIMAL**, **SS_TV_APP**, **SS_INTE**, **TOTAL_SERVICIOS**, **MONTO_POR_SS** y **EVENTOS_DISTINTOS**. Estas variables sugieren que el abandono se relaciona con una combinación de antigüedad, valor económico, ubicación geográfica, servicios contratados y paquetización.

En el bloque no supervisado se aplicaron K-Means y Clustering Jerárquico. Ambos modelos seleccionaron **3 clusters** como mejor configuración según Silhouette Score. K-Means obtuvo un Silhouette de **0,1319** sobre el dataset completo, mientras que el Clustering Jerárquico obtuvo **0,1467** sobre una muestra de 8.000 registros. Aunque los valores son moderados-bajos, los segmentos son interpretables y permiten extraer perfiles útiles de clientes.

En K-Means, el **Cluster 0** presentó la mayor tasa de abandono, con **4,25%**. Este grupo tiene menor paquetización promedio, menor antigüedad y menor valor neto promedio, por lo que puede interpretarse como un segmento de clientes menos consolidados y de mayor riesgo. El **Cluster 1** mostró la menor tasa de abandono, con **2,91%**, mayor antigüedad promedio, mayor cantidad de servicios y mayor valor neto promedio, por lo que representa clientes más consolidados y fidelizados. El **Cluster 2** presentó una tasa intermedia de **3,91%**, con menor exposición a eventos técnicos y características territoriales diferenciadas.

El Clustering Jerárquico refuerza una lectura similar. El cluster con menor abandono fue el grupo de clientes con mayor antigüedad, mayor paquetización y mayor valor neto promedio, mientras que los grupos con menor consolidación comercial mostraron tasas de abandono superiores. Esto respalda la hipótesis de que la antigüedad y la paquetización están asociadas a mayor retención.

Finalmente, las reglas de asociación Apriori permitieron identificar patrones de contratación conjunta. Dado que todos los clientes residenciales tienen Internet, este servicio no discrimina por sí solo. Las reglas más relevantes aparecen en combinaciones como **ALARMCOM -> SVA**, con confianza **1,0000** y lift **4,1940**, y **TNT_SPORT -> TV**, con confianza **0,9680** y lift **1,8252**. También destacan reglas como **TELEFONIA -> TV**, con confianza **0,8252** y lift **1,5558**.

Estas reglas sugieren que ciertos servicios funcionan como anclas de paquetización. Por ejemplo, los clientes con TNT Sport tienden fuertemente a estar asociados a TV, y los clientes con Telefonía presentan una alta relación con TV. Estos patrones pueden utilizarse para diseñar campañas de cross-selling orientadas a clientes con baja paquetización y alto riesgo estimado de abandono.

En conjunto, la fase de modelamiento muestra que el abandono puede abordarse desde tres niveles: predicción individual de riesgo mediante modelos supervisados, segmentación de perfiles mediante clustering y diseño de ofertas mediante reglas de asociación. Esta combinación permite pasar del análisis técnico a una estrategia de retención más accionable.

Decisión de modelo y uso recomendado

Se selecciona la **Regresión Logística balanceada** como modelo supervisado principal, debido a que logra el mejor equilibrio entre Recall, F1-Score e interpretabilidad. Su principal valor no es predecir con certeza absoluta qué cliente abandonará, sino priorizar clientes con mayor riesgo estimado.

Para segmentación, se prioriza **K-Means** como modelo no supervisado operativo, ya que permite aplicar clustering sobre toda la base de clientes. El Clustering Jerárquico se mantiene como contraste exploratorio sobre muestra, útil para validar la existencia de perfiles similares.

Las reglas Apriori complementan el análisis al identificar combinaciones de servicios que pueden orientar campañas de retención y venta cruzada. En particular, los patrones asociados a TV, Telefonía, SVA, TNT Sport y Alarmcom pueden utilizarse para diseñar ofertas de empaquetamiento dirigidas a clientes con baja paquetización y mayor riesgo.

Contraste de hipótesis iniciales

Hipótesis 1:

Los clientes residenciales con mayor cantidad de reclamos, exposición a fallas masivas o problemas técnicos presentan una mayor probabilidad de abandono parcial.

Esta hipótesis se confirma solo parcialmente. Las variables técnicas y de reclamos fueron consideradas en el modelamiento, pero no aparecieron como los factores más determinantes del abandono. En el Árbol de Decisión, `EVENTOS_DISTINTOS` aparece con baja importancia relativa, mientras que variables como `TNT_SPORT_VIGENTE`, `ANTG_MESES_TODO`, `LATITUD_DECIMAL`, `VLOR_NETO_PROM` y `CRUCE_ACTIVO_VOZ+BA+TV` tuvieron mayor peso.

Además, en la segmentación K-Means, el cluster con mayor tasa de abandono, equivalente a **4,25%**, no fue necesariamente el que concentró más reclamos promedio. Por lo tanto, los reclamos y eventos técnicos pueden aportar señal, pero no parecen explicar por sí solos el abandono parcial residencial. La evidencia es mixta y sugiere que el abandono no depende únicamente de problemas técnicos, sino de una combinación de factores comerciales, territoriales y de servicios.

Conclusión sobre la Hipótesis 1:

La hipótesis queda **parcialmente respaldada**, pero no confirmada como principal explicación del abandono.

Hipótesis 2:

Los clientes residenciales con menor nivel de paquetización, menor antigüedad o menor cantidad de servicios contratados presentan una mayor probabilidad de abandono parcial.

Esta hipótesis sí encuentra mayor respaldo en los resultados. En la segmentación K-Means, el cluster con mayor tasa de abandono fue el **Cluster 0**, con **4,25%**, caracterizado por menor cantidad promedio de servicios contratados, menor antigüedad relativa y menor valor neto promedio. En contraste, el **Cluster 1** presentó la menor tasa de abandono, con **2,91%**, y agrupó clientes con mayor antigüedad, mayor paquetización y mayor valor económico.

Además, en los modelos supervisados, `ANTG_MESES_TODO`, `CRUCE_ACTIVO_VOZ+BA+TV`, `SS_INTE`, `TOTAL_SERVICIOS` y `VLOR_NETO_PROM` aparecen como variables relevantes para explicar diferencias de riesgo. Esto refuerza la idea de que clientes más consolidados comercialmente tienden a presentar menor probabilidad de abandono.

Conclusión sobre la Hipótesis 2:

La hipótesis queda **respaldada por los resultados**, especialmente desde la segmentación no supervisada y la importancia de variables del modelo.

d) Conclusiones

El proyecto permitió aplicar una estrategia de minería de datos sobre clientes residenciales para analizar el abandono parcial y proponer acciones de retención basadas en evidencia. El segmento residencial concentra la mayor parte de la base, con **163.262 registros**, por lo que resulta un foco relevante para el negocio.

La variable objetivo **ABANDONO_FULL** presenta una tasa positiva de **3,49%**, lo que confirma que el abandono es un evento poco frecuente y que el problema debe tratarse como una clasificación desbalanceada. Por esta razón, métricas como **Recall**, **F1-Score**, **ROC-AUC** y **PR-AUC** resultan más relevantes que Accuracy.

Durante la comprensión y preparación de datos se identificaron variables con fuga de información, columnas constantes, variables completamente nulas, duplicados y campos no informativos. La exclusión de estas variables permitió construir una base más consistente para el modelamiento, reduciendo el riesgo de obtener resultados artificialmente optimistas.

El análisis exploratorio mostró que ninguna variable numérica aislada explica fuertemente el abandono. Esto sugiere que el fenómeno depende de una combinación de factores comerciales, técnicos, territoriales y de servicios contratados, más que de una única causa directa.

En el modelamiento supervisado, la **Regresión Logística balanceada** fue seleccionada como modelo principal, ya que obtuvo el mejor equilibrio entre **F1-Score**, **Recall** e interpretabilidad. El modelo logró detectar **1.235 de los 1.707 abandonos reales** del conjunto de prueba, alcanzando un **Recall** de **72,35%**.

Aunque la precisión del modelo es baja, esto no invalida su utilidad para el negocio. En campañas de retención, un falso positivo implica contactar a un cliente que probablemente no iba a abandonar, lo cual puede tener un costo comercial, pero no necesariamente genera daño directo. En cambio, un falso negativo implica no detectar a un cliente que sí abandona, lo que puede traducirse en pérdida real de ingresos. Por lo tanto, en este caso es razonable priorizar modelos con mayor capacidad de detección de abandonos.

El análisis no supervisado permitió identificar segmentos diferenciados de clientes. K-Means detectó tres grupos principales: un segmento de mayor riesgo con menor antigüedad y menor paquetización, un segmento más consolidado con mayor antigüedad y mayor cantidad de servicios, y un segmento territorialmente diferenciado con riesgo intermedio. Esto permite orientar acciones de retención según perfil de cliente.

Las reglas de asociación permitieron descubrir patrones de contratación conjunta de servicios. Servicios como TV, Telefonía, SVA, TNT Sport y Alarmcom aparecen relacionados en combinaciones con alto lift o

confianza, lo que sugiere oportunidades de empaquetamiento y venta cruzada para fortalecer la permanencia del cliente.

En conjunto, los resultados muestran que el abandono residencial puede abordarse combinando tres niveles de análisis: predicción de riesgo individual, segmentación de clientes y reglas de contratación conjunta. Esta combinación permite transformar los datos en una herramienta práctica para priorizar clientes, diseñar campañas de retención y orientar decisiones comerciales.

Como recomendación general, el modelo no debe utilizarse como una decisión automática de contacto masivo, sino como un sistema de priorización. La empresa debería focalizar sus campañas en clientes con mayor riesgo estimado, especialmente aquellos con baja paquetización, menor antigüedad o pertenecientes a segmentos con mayor tasa de abandono.


Finalmente, se recomienda recalibrar los modelos periódicamente con nuevos datos y medir el resultado real de las campañas aplicadas. Esto permitiría ajustar umbrales, reducir costos de contacto, mejorar la precisión de las acciones comerciales y aumentar el valor generado por la solución analítica.

Anexos Para Presentación

Configuración visual lista.


	segmento	registros	porcentaje
1	NEGOCIOS	17013	9.4400
0	RESIDENCIAL	163262	90.5600

El segmento residencial concentra la oportunidad de retención




	clase	registros	porcentaje	clase_texto
0	0	157570	96.5100	No abandono
1	1	5692	3.4900	Abandono

El abandono es poco frecuente: Accuracy puede engañar




	etapa	registros
0	Base residencial inicial	163262
1	Duplicados eliminados	240
2	Dataset preparado	163022

La base fue depurada sin perder volumen relevante




	variable	correlacion	correlacion_abs
0	ANTG_MESES_TODO	-0.0555	0.0555
1	VLOR_NETO_PROM	-0.0498	0.0498
2	SS_TEL	-0.0463	0.0463
9	TOTAL_SERVICIOS	-0.0425	0.0425
3	SS_TV	-0.0384	0.0384
4	SS_TV_APP	0.0336	0.0336
5	MESES_COBROS	-0.0319	0.0319
6	VELOCIDAD_BAJADA	-0.0286	0.0286

El abandono no depende de una sola variable




	modelo	recall	precision	f1_score	roc_auc	pr_auc
0	Regresión logística balanceada	72.3500	5.1500	9.6200	0.6680	6.2900
3	SVM lineal balanceado	72.9900	5.1500	9.6100	0.6680	6.2700
1	Árbol de decisión balanceado	76.8600	4.6700	8.8100	0.6390	5.3600
2	Naive Bayes	0.1200	7.1400	0.2300	0.6350	5.1000

La Regresión Logística equilibra detección e interpretabilidad



	Predicho no abandono	Predicho abandono
Real no abandono	24469	22731
Real abandono	472	1235

El modelo detecta 1.235 abandonos reales




En retención, el falso negativo es más costoso: no detectar a un cliente que efectivamente abandona.

	CLUSTER_KMEANS	nombre_cluster	clientes	porcentaje_clientes	tasa_abandono	total_servicios_prom	antiguedad_pro
1	1	Consolidados y paquetizados	89021	54.6100	2.9100	2.8201	115.0485
2	2	Territorial diferenciado	12664	7.7700	3.9100	1.7063	60.3033
0	0	BA menos consolidados	61337	37.6200	4.2500	1.2647	50.7319




Los clientes menos consolidados concentran mayor riesgo



	Regla	Soporte (%)	Confianza (%)	Lift	Abandono grupo (%)
19	ALARMCOM → SVA	1.0600	100.0000	4.1900	0.5800
66	ALARMCOM + TV → SVA	0.6800	100.0000	4.1900	0.3600
64	ALARMCOM → SVA + TV	0.6800	63.8900	4.0500	0.3600
67	TNT_SPORT → TELEFONIA + TV	2.5200	42.0300	2.3300	0.0000
61	TNT_SPORT → SVA + TV	1.9400	32.4400	2.0600	0.0000
69	TNT_SPORT + TV → TELEFONIA	2.5200	43.4200	1.9800	0.0000
20	TNT_SPORT → TELEFONIA	2.5300	42.3000	1.9300	0.0000

Algunas combinaciones de servicios funcionan como anclas de fidelización



	Campaña	Clientes priorizables	% base residencial	Abandono real histórico (%)	Score riesgo promedio (%)	Servicio
0	Pack base para BA en riesgo	18293	11.2200	6.5400	65.0500	1.3200
2	Ancla deportiva para clientes TV	10009	6.1400	6.4400	63.4500	2.4100
3	Protección de clientes consolidados	4096	2.5100	7.2500	66.7300	2.4800
1	Cross-selling Telefonía a TV	720	0.4400	5.1400	64.4000	2.5700



El modelo permite transformar riesgo en campañas concretas

